

1. Không có RAG

```
inputs = tokenizer([
    alpaca_prompt.format(
        "Lý do nào khiến Itachi tha mạng cho Sasuke trong lần tàn sát gia tộc?", # instruction
        "", # input
        "", # output - leave this blank for generation!
    )
], return_tensors = "pt").to("cuda")

from transformers import TextStreamer
text_streamer = TextStreamer(tokenizer)
_ = model.generate(**inputs, streamer = text_streamer, max_new_tokens = 128)
```

<bos>Below is an instruction that describes a task, paired with an input that provides further context. Write a response that appropriately completes the request.

Instruction:
Lý do nào khiến Itachi tha mạng cho Sasuke trong lần tàn sát gia tộc?

Input:

Response:
Itachi tha mạng cho Sasuke để Sasuke có thể sống sót và trở thành một ninja mạnh mẽ, có thể bảo vệ làng và gia tộc.<eos>

2. Có RAG

```
query_text = "Vì sao Itachi lại không giết Sasuke trong lần tàn sát gia tộc của mình?" # Replace with your desired query

# Call query_rag with the query text
query_rag(query_text)
```

Response:
Itachi muốn cho Sasuke trưởng thành và chứng minh giá trị của tình yêu thương, cũng như hy vọng Sasuke sẽ có một cuộc sống tốt đẹp hơn.

Sources: ['data/ChatGPT-Naruto.pdf:93:2', 'data/ChatGPT-Naruto.pdf:38:3', 'data/ChatGPT-Naruto.pdf:69:3', 'data/Itachi_Uchiha_information.pdf:21:2', 'data/Naruto_character_information.pdf:1:2']

\nItachi muốn cho Sasuke trưởng thành và chứng minh giá trị của tình yêu thương, cũng như hy vọng Sasuke sẽ có một cuộc sống tốt đẹp hơn.'

*** Theo em thấy, khi không có Rag thì model trả lời không có chiều sâu và không được cụ thể bằng lúc có Rag